



Busca en Internet información sobre estas cuestiones:

- Modifica el ejemplo del fichero Celsius_Fahrenheit (número de capas, por ejemplo, número de valores de prueba, etc.). Muestra el código final y ¿el sistema sigue siendo correcto en sus valores?

```
#-----  
-----  
# RED NEURONAL CELSIUS - FAHRENHEIT  
#-----  
-----  
#-----  
-----  
# Importación de Frameworks  
#-----  
-----  
import tensorflow as tf  
import numpy as np  
import random  
.  
#-----  
-----  
# Tablas con los valores asociados  
#-----  
-----  
#celsius = np.array( [ -100, -40, -10, 0, 8, 15, 22, 38  
], dtype = float )  
#fahrenheit = np.array( [ -148, -40, 14, 32, 46, 59, 72,  
100 ], dtype = float )  
.  
celsius = np.array( [] )  
#for i in range( 20 ):  
for i in range( random.randint( 10, 50 ) ):  
    grado = random.randrange( -1000, 1000, 1 )  
    error = (.5 - random.random()) * grado  
    celsius = np.append( celsius, grado ) + error  
.  
fahrenheit = np.array( [] )  
for grado_celsius in celsius:
```



```
• grado_fahrenheit = grado_celsius * 1.8 + 32
• error = (.5 - random.random()) * grado
• fahrenheit = np.append( fahrenheit, grado_fahrenheit +
error )
•
• #-----
• -----
• # Definición de las capas
• #-----
• -----
• # tf.keras.layers.Dense
• # Define una capa de tipo densa (Dense), que implica
conexiones son todas
• # las neuronas de la siguiente capa.
• #
• # units = 1
• # Define una (1) única neurona de salida.
• #
• # input_shape = [ 1 ]
• # Define una capa de entrada con una (1) sola neurona.
• #
• # modelo = tf.keras.Sequential( [ capa ] )
• # Define el modelo de capa de tipo Secuencial con una
única capa.
• #-----
• -----
• capa = tf.keras.layers.Dense( units = 4, input_shape = [ 1 ]
)
• modelo = tf.keras.Sequential( [ capa ] )
•
• #-----
• -----
• # Definición del optimizador y de la función de pérdida
• #-----
• -----
• # El optimizador unitilizado es al algoritmo Adam, al que se
le pasa un valor
• # entre 0 y 1.
```



```
• #-----  
• -----  
• modelo.compile(  
•     optimizer = tf.keras.optimizers.Adam( 0.05 ), # Nivel de  
•     ajuste  
•     loss = 'mean_squared_error'  
• )  
•  
• #-----  
• -----  
• # Entrenamiento del modelo  
• #-----  
• -----  
• # Se utiliza la función fit sobre el modelo, especificando:  
• #   - Datos de entrada:                'celsius'  
• #   - Datos de salida esperados:       'fahrenheit'  
• #   - Número de interacciones:         'epochs'  
• #   - Si muestra evolución por pantalla: 'verbose'  
• #-----  
• -----  
• print( "Comenzamos el entrenamiento ..." )  
• historial = modelo.fit( celsius,  
•                          fahrenheit,  
•                          epochs = 500,  
•                          verbose = False )  
•  
• print( "Modelo ya entrenado" )  
•  
• #-----  
• -----  
• # Muestra de los resultados obtenidos  
• #-----  
• -----  
• import matplotlib.pyplot as plt  
• plt.xlabel( "Celsius" )  
• plt.ylabel( "Fahrenheit" )  
•  
• plt.scatter( celsius, fahrenheit, color = 'green' )
```



```
• plt.plot( celsius, modelo.predict( celsius ) )  
• plt.show()  
•  
• print( "Variables internas del modelo" )  
• print( capa.get_weights() )  
•  
• print( "Hagamos una predicción" )  
• #celsius_prueba = random.randint( -500, 500 )  
• celsius_prueba = 100  
• resultado = modelo.predict( [ celsius_prueba ] )  
• print( str( celsius_prueba ) + "°C son " + str( resultado )  
+ "° fahrenheit" )
```

Al modificar el numero de units en una capa densa de una red neuronal, estoy aumentando la capacidad del modelo para aprender representaciones mas complejas de los datos, aprender patrones complejos pero tambien lo hace mas propenso al sobreajuste y aumenta el tiempo de entrenamiento.



- Modifica el ejemplo del Árbol_de_decisión. Por ejemplo, busca cómo modificar el número de capas y ramas. Muestra el código final y ¿el sistema sigue siendo correcto en sus valores?

```
#-----  
#-----  
#  INSTALAMOS LIBRERÍAS  
#-----  
#-----  
import pandas as pd  
import matplotlib.pyplot as plt  
.  
#-----  
#-----  
#  CARGAMOS LOS DATOS  
#-----  
#-----  
df = pd.read_csv( "problemas_del_corazon.csv" )  
.  
#-----  
#-----  
#  DATOS DE ENTRENAMIENTO Y PRUEBA  
#-----  
#-----  
from sklearn.model_selection import train_test_split  
#-----  
#-----  
datos = [ "edad", "genero", "presion" ]  
objetivo = [ "uso de internet" ]  
datos_entrena, datos_prueba, clase_entrena, clase_prueba =  
train_test_split(  
    df[ datos ],  
    df[ "diabetico" ],
```



```
• test_size = 0.25 # 20
• )
•
• #-----
• # CREACIÓN DEL ÁRBOL DE DECISIÓN
• #-----
•
• from sklearn import tree
• #-----
•
• arbol_decision = tree.DecisionTreeClassifier(
•     criterion = "gini", # gini, entropy, log_loss
•     splitter = "best", # best, random
•     max_depth = 4
• )
•
• arbol = arbol_decision.fit(datos_entrena, clase_entrena)
•
• plt.figure( figsize = ( 20, 15 ) )
• tree.plot_tree( arbol,
•
•     max_depth = 4,
•     #feature_names=[ "sexo", "edad"],
•     feature_names = datos,
•     filled = True,
•     impurity = False,
•     precision = 0
• )
•
• plt.show()
```

Modifique la profundidad maxima del arbol a 4 y el criterion a gini, esto hace que se modifique la forma de evaluar la calidad de las divisiones del arbol, reducir la profundidad maxima del arbol hace que el modelo sea menos complejo pero tambien reduce su capacidad de encontrar patrones complejos en los datos, dando lugar a un posible mayor sesgo. Pero aun con todo los datos siguen siendo validos, pero el rendimiento del modelo puede verse afectado por los cambios.