



Busca en Internet información sobre estas cuestiones:

- A tu disposición tienes dos árboles de decisión: uno sobre compras y alquileres de una Vivienda, y otro sobre problemas de corazón:
 - En 'datos' aparecen los campos que se tomarán en cuenta a la hora de generar el árbol de decisión.
 - En 'total_size' es el porcentaje de los datos que se convertirán en parte de entrenamiento.
 - En 'max_depth' como profundidad máxima del árbol de decisión.
 - En 'criterion' como método para generar el árbol de decisión.
 - En 'splitter' para realizarlo de la mejor forma o de forma aleatoria.
- Cambia algunos de los valores en los campos anteriores y observa el resultado. Guarda varias imágenes de los cambios efectuados y de gráfico asociado.

En este primer ejemplo se puede ver el árbol de decisiones resultante de modificar el **test_size** a un valor de 1 y el **max_depth** a un valor de 4.

```
File Edit Selection View Go Run Terminal Help
Tarea 3. Árbol decisión, Comprar y alquilar.ipynb
Curso de IA & Big Data > Modelos de inteligencia artificial > Tarea 3. Árboles de decisión > Tarea 3. Árbol decisión, Comprar y alquilar.ipynb > ...
+ Code + Markdown | Run All | Restart | Clear All Outputs | Variables | Outline | ...
Python 3.8.19

# DATOS DE ENTRENAMIENTO Y PRUEBA
#-----
from sklearn.model_selection import train_test_split

#-----
datos = [ "ingresos", "gastos_comunes", "pago_coche", "gastos_otros", "ahorros", "estado_civil", "hijos", "trabajo" ]
datos_entrena, datos_prueba, clase_entrena, clase_prueba = train_test_split(
    df[ datos ],
    df[ "comprar" ],
    test_size = 1          # 20
)

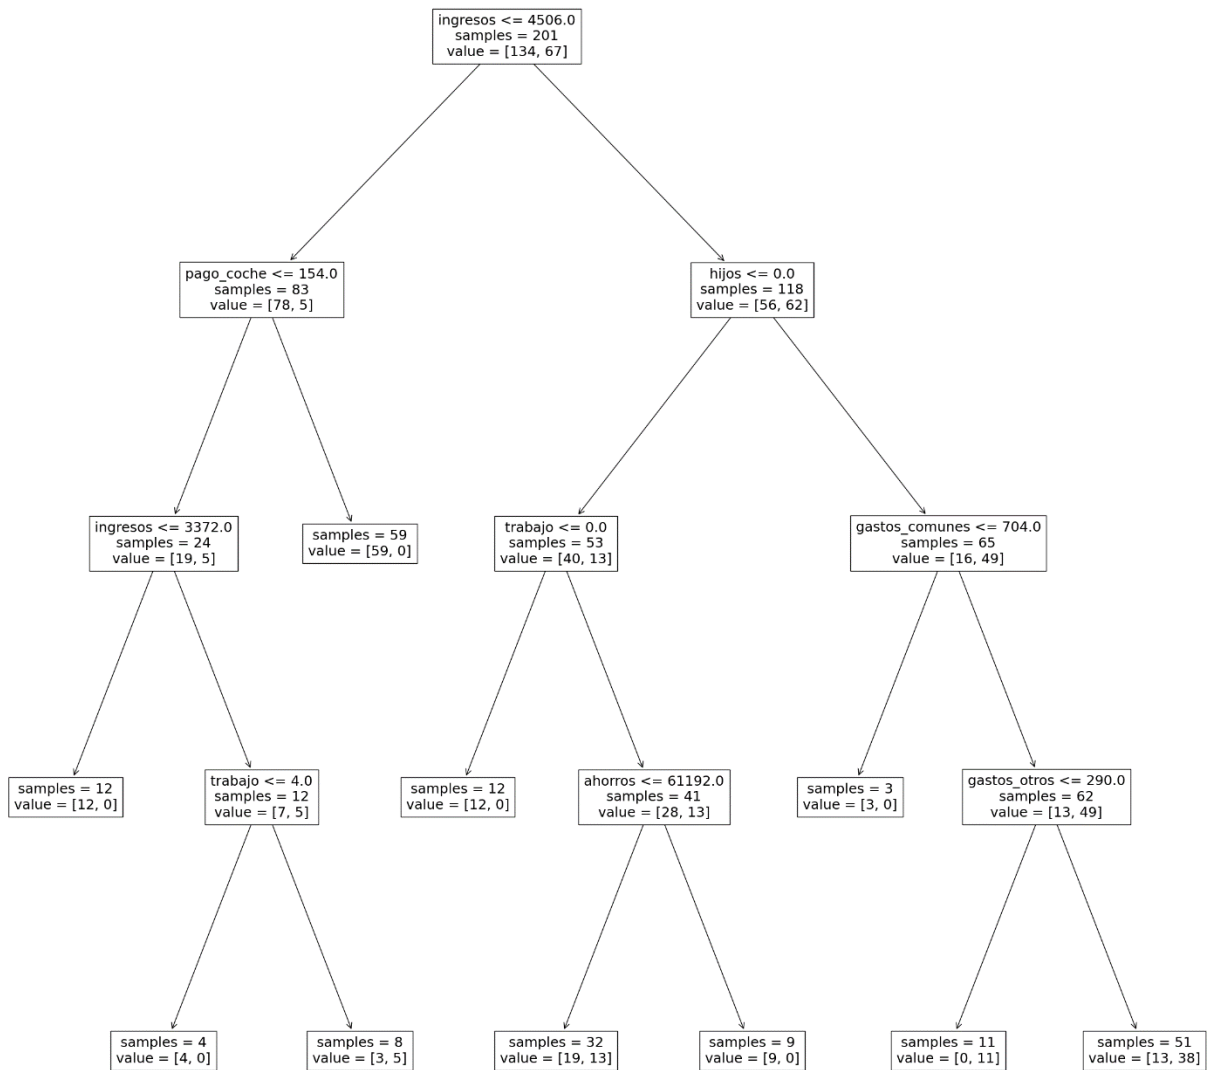
# CREACIÓN DEL ÁRBOL DE DECISIÓN
#-----
from sklearn import tree

#-----
arbol_decision = tree.DecisionTreeClassifier(
    criterion = "entropy",      # gini, entropy, log_loss
    splitter = "best",         # best, random
    max_depth = 4
)

arbol = arbol_decision.fit(datos_entrena, clase_entrena)

plt.figure( figsize = ( 30, 30 ) )
tree.plot_tree( arbol,
    max_depth = 4,
    feature_names = datos,
    filled = False,
    impurity = False,
    precision = 0
)

plt.show()
```





En este siguiente ejemplo se mantienen las modificaciones anteriores y se modifica el valor de **criterion** al valor “gini”.

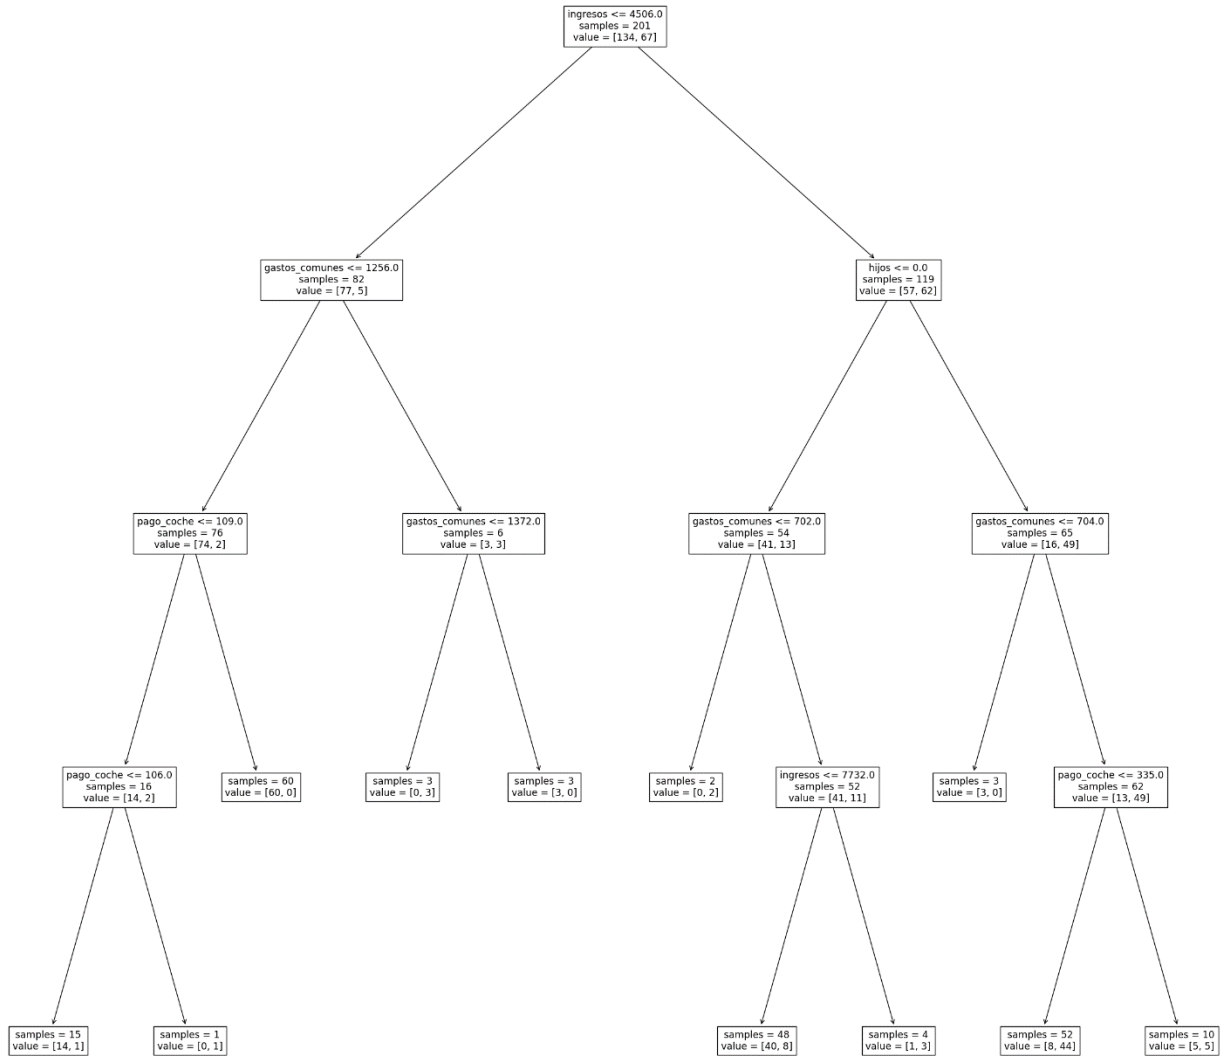
```
File Edit Selection View Go Run Terminal Help
Tarea 3. Árbol decisión. Comparar y alquilar.ipynb
Curso de IA & Big Data > Modelos de inteligencia artificial > Tarea UT-3 > Tarea 3. Árboles de decisión > Tarea 3. Árbol decisión. Comparar y alquilar.ipynb > ...
+ Code + Markdown + Run All + Restart + Clear All Outputs + Variables + Outline ...
# DATOS DE ENTRENAMIENTO Y PRUEBA
#-----
from sklearn.model_selection import train_test_split
#-----
datos = [ "ingresos", "gastos_comunes", "pago_coche", "gastos_otros", "ahorros", "estado_civil", "hijos", "trabajo" ]
datos_entrena, datos_prueba, clase_entrena, clase_prueba = train_test_split(
    df[ datos ],
    df[ "comprar" ],
    test_size = 1          # 20
)

# CREACIÓN DEL ÁRBOL DE DECISIÓN
#-----
from sklearn import tree
#-----
arbol_decision = tree.DecisionTreeClassifier(
    criterion = "gini",      # gini, entropy, log_loss
    splitter = "best",      # best, random
    max_depth = 4
)

arbol = arbol_decision.fit(datos_entrena, clase_entrena)

plt.figure( figsize = ( 30, 30 ) )
tree.plot_tree( arbol,
    max_depth = 4,
    feature_names = datos,
    filled = False,
    impurity = False,
    precision = 0
)

plt.show()
```





- Genera un árbol de decisión con alguna de las bases de datos incorporadas, o, con cualquier otra base de datos que tengas a tu disposición.

Curso de IA & Big Data > Modelos de inteligencia artificial > Tarea UT-3 > Tarea 3. Árboles de decisión > Vinapio.ipynb > ...

```
# -----  
#  INSTALAMOS LIBRERÍAS  
# -----  
import pandas as pd  
import matplotlib.pyplot as plt  
  
# -----  
#  CARGAMOS LOS DATOS  
# -----  
df = pd.read_csv( "winequality-red.csv" )  
df
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	7.4	0.700	0.00	1.9	0.076	11.0	34.0	0.99780	3.51	0.56	9.4	5
1	7.8	0.880	0.00	2.6	0.098	25.0	67.0	0.99680	3.20	0.68	9.8	5
2	7.8	0.760	0.04	2.3	0.092	15.0	54.0	0.99700	3.26	0.65	9.8	5
3	11.2	0.280	0.56	1.9	0.075	17.0	60.0	0.99800	3.16	0.58	9.8	6
4	7.4	0.700	0.00	1.9	0.076	11.0	34.0	0.99780	3.51	0.56	9.4	5
...
1594	6.2	0.600	0.08	2.0	0.090	32.0	44.0	0.99490	3.45	0.58	10.5	5
1595	5.9	0.550	0.10	2.2	0.062	39.0	51.0	0.99512	3.52	0.76	11.2	6
1596	6.3	0.510	0.13	2.3	0.076	29.0	40.0	0.99574	3.42	0.75	11.0	6
1597	5.9	0.645	0.12	2.0	0.075	32.0	44.0	0.99547	3.57	0.71	10.2	5
1598	6.0	0.310	0.47	3.6	0.067	18.0	42.0	0.99549	3.39	0.66	11.0	6

1599 rows × 12 columns

Curso de IA & Big Data > Modelos de inteligencia artificial > Tarea UT-3 > Tarea 3. Árboles de decisión > Vinapio.ipynb > ...

```
# -----  
#  DATOS DE ENTRENAMIENTO Y PRUEBA  
# -----  
from sklearn.model_selection import train_test_split  
# -----  
datos = [ "fixed acidity", "volatile acidity", "citric acid", "residual sugar", "chlorides", "free sulfur dioxide", "total sulfur dioxide", "density", "pH", "sulphates", "alcohol"  
datos_entrena, datos_prueba, clase_entrena, clase_prueba = train_test_split(  
    df[ datos ],  
    df[ "quality" ],  
    test_size = 0.75  
    # 20  
)  
  
# -----  
#  CREACIÓN DEL ÁRBOL DE DECISIÓN  
# -----  
from sklearn import tree  
# -----  
arbol_decision = tree.DecisionTreeClassifier(  
    criterion = "entropy",      # gini, entropy, log_loss  
    splitter = "best",         # best, random  
    max_depth = 4  
)  
  
arbol = arbol_decision.fit(datos_entrena, clase_entrena)  
  
plt.figure( figsize = ( 30, 30 ) )  
tree.plot_tree( arbol,  
    max_depth = 4,  
    feature_names = datos,  
    filled = False,  
    impurity = False,  
    precision = 0  
    )  
plt.show()
```

1.3s

