



Busca en Internet información sobre estas cuestiones:

- A tu disposición tienes un algoritmo de KNN (K vecinos más cercanos) como un ejemplo de un algoritmo de agrupamiento, en el que tienes descrito sus campos.
 - En 'n_neighbors' como número de vecinos.
 - En 'weights' como función de peso en la predicción.
 - En 'leaf_size' como tamaño de la hoja.
 - En 'metric' como métrica para el cálculo de la distancia.
 - En 'verbose' como ejecución comentada.
 - En 'algorithm' como algoritmo que se empleará para hacer las agrupaciones.
- Cambia algunos de los valores en los campos anteriores y observa el resultado. Guarda varias imágenes de los cambios efectuados y del gráfico asociado.

Creación del Modelo KNN

Valor de K

```
#-- CREAMOS EL MODELO KNN
#-----
# n_neighbors número de vecinos (int). Por defecto es 5
# weights función de peso de la predicción (uniform, distance). Por defecto es uniform
# algorithm algoritmo de cálculo (ball_tree, kd_tree, brute, auto). Por defecto es auto
# leaf_size tamaño de hoja de cálculo (int). Por defecto es 30
# p parámetro de potencia (int). Por defecto es 2
# metric métrica sobre la distancia ("minkowski", "precomputed"). Por defecto es "minkowski"
# metric_params argumentos adicionales ("") . Por defecto es None
# n_jobs número de trabajos en paralelo (int) Por defecto es None
#-----
clasificador = KNeighborsClassifier(
    n_neighbors = 3,
    weights = "distance",
    algorithm = "brute",
    leaf_size = 100,
    p = 3,
    metric = "minkowski",
    n_jobs = None
)

clasificador.fit( datos, clase )
```

Imagen 1 Código Original




Imagen 2 Grafico Zonas Original



```
#-----  
# CREAMOS EL MODELO KNN  
#-----  
# n_neighbors número de vecinos (int). Por defecto es 5  
# weights función de peso de la predicción (uniform, distance). Por defecto es uniform  
# algorithm algoritmo de cálculo (ball_tree, kd_tree, brute, auto). Por defecto es auto  
# leaf_size tamaño de hoja de cálculo (int). Por defecto es 30  
# p parámetro de potencia (int). Por defecto es 2  
# metric métrica sobre la distancia ("minkowski", "precomputed"). Por defecto es "minkowski"  
# metric_params argumentos adicionales (""). Por defecto es None  
# n_jobs número de trabajos en paralelo (int). Por defecto es None  
#-----  
clasificador = KNeighborsClassifier(  
    n_neighbors = 6,  
    weights = "uniform",  
    algorithm = "ball_tree",  
    leaf_size = 100,  
    p = 3,  
    metric = "minkowski",  
    n_jobs = None  
)  
  
clasificador.fit( datos, clase )
```

KNeighborsClassifier
KNeighborsClassifier(algorithm='ball_tree', leaf_size=100, n_neighbors=6, p=3)

Imagen 3 Código Modificado




Imagen 4 Zonas Código Modificado



- Prueba a realizar a partir del ejemplo de la Concesión de créditos, uno similar con los datos del Titanic, teniendo en consideración los pasajeros que sobrevivieron (o no) en función de su edad y Tarifa de billete.

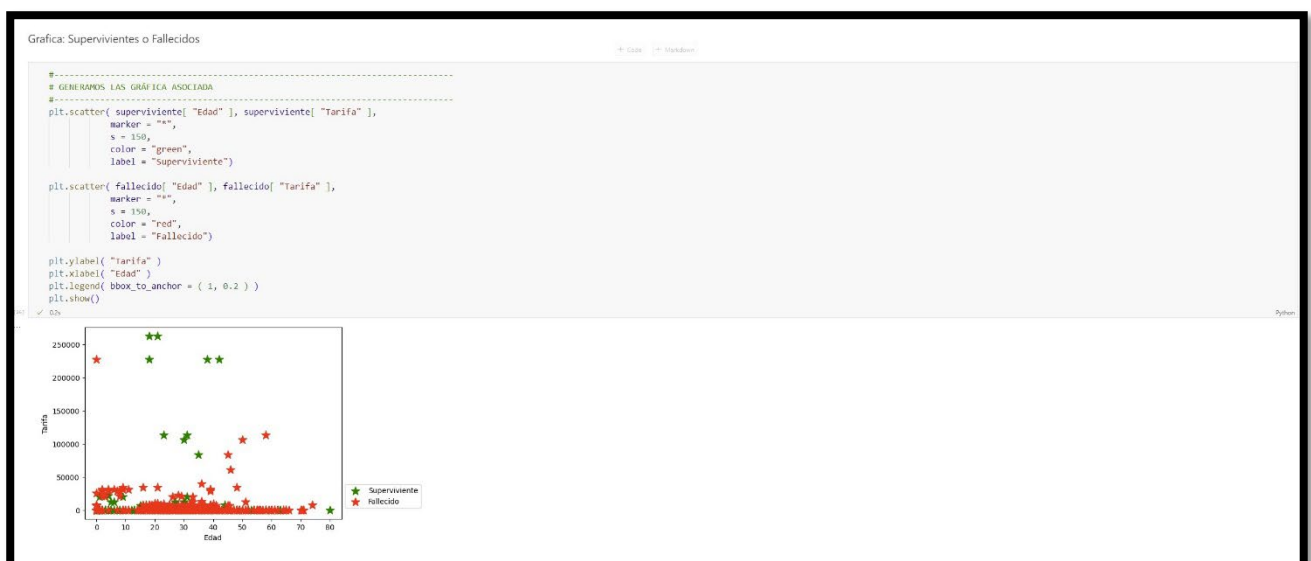
```
Code Run AI Reset Clear All Outputs Variables Outline Python 3.8.10
```

```
#-----  
# IMPORTAMOS LAS LIBRERÍAS  
#-----  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
import random  
from sklearn import preprocessing  
from sklearn.neighbors import KNeighborsClassifier  
  
#-----  
# CARGAMOS LOS DATOS  
#-----  
pasajeros = pd.read_csv("titanic.csv")  
pasajeros
```

IdPasajero	Sobrevivió	Clase	Nombre	Sexo	Edad	Hermanos familiares	Padres hijos	Ticket	Tarifa	Cabina	Embarcado
0	1	0	Braund, Mr. Owen Harris	hombre	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	Cummings, Mrs. John Bradley (Florence Briggs Th...	mujer	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	Heikinen, Miss. Laina	mujer	26.0	0	0	STON/O2. 3101282	7925.0000	NaN	S
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	mujer	35.0	1	0	113803	53.1000	C123	S
4	5	0	Allen, Mr. William Henry	hombre	35.0	0	0	373450	8.0500	NaN	S
...
886	887	0	Monvilla, Ray, Juozas	hombre	27.0	0	0	211536	13.0000	NaN	S
887	888	1	Graham, Miss. Margaret Edith	mujer	19.0	0	0	112053	30.0000	B42	S
888	889	0	Johnston, Miss. Catherine Helen "Carla"	mujer	0.0	1	2	W/C 6607	23.4500	NaN	S
889	890	1	Behr, Mr. Karl Howell	hombre	26.0	0	0	111369	30.0000	C148	C
890	891	0	Dooley, Mr. Patrick	hombre	32.0	0	0	370376	7.7500	NaN	Q

891 rows x 12 columns

```
SUPERVIVIENTES Y FALLECIDOS  
  
superviviente = pasajeros[pasajeros["sobrevivió"] == 1]  
fallecido = pasajeros[pasajeros["sobrevivió"] == 0]
```





```
datos = pasajeros[ [ "Edad", "Tarifa" ] ]
datos = datos.dropna()
datos = datos.apply(pd.to_numeric)
clase = pasajeros[ "Sobrevivió" ]

escalador = preprocessing.MinMaxScaler()
datos = escalador.fit_transform(datos)
```

CREACION MODELO KNN

```
clasificador = KNeighborsClassifier(
    n_neighbors = 6,
    weights = "uniform",
    algorithm = "ball_tree",
    leaf_size = 100,
    p = 3,
    metric = "minkowski",
    n_jobs = None
)

clasificador.fit( datos, clase )
```

```
KNeighborsClassifier(algorithm='ball_tree', leaf_size=100, n_neighbors=6, p=3)
```

NUEVO PASAJERO

```
edad = random.randint( 5, 80 )
print (edad)
tarifa = random.randint(1000,300000)
print (tarifa)
viajero = escalador.transform( [ [ edad, tarifa ] ] )

plt.scatter( superviviente[ "Edad" ], superviviente[ "Tarifa" ],
    marker = "x",
    s = 150,
    color = "skyblue",
    label = "Superviviente"
)

plt.scatter( fallecido[ "Edad" ], fallecido[ "Tarifa" ],
    marker = "x",
    s = 150,
    color = "red",
    label = "Fallecido"
)

plt.scatter( edad, tarifa, marker = "p", s = 250, color = "blue", label = "viajero" )
plt.ylabel( "Tarifa" )
plt.xlabel( "Edad" )
plt.legend( bbox_to_anchor = ( 1, 0.3 ) )
plt.show()
```

